# 1 book recommends

November 4, 2024

# 1 Recomendación de libros con KNN

Alumno: Rodolfo Luthe Narváez

#### 1.1 Justificación

Soy un lector ávido, regularmente leo libros de ficción y tengo la necesidad de conseguir nuevas recomendaciones constantemente. Como la clase de Machine Learning necesita que usemos un algoritmo de aprendizaje y lo entrenemos con un buen volumen de datos pienso que este proyecto es apropiado para presentar este semestre para resolver mi necesidad de tener tema para el proyecto y de conseguir mas recomendaciones para mi.

## 1.2 Objetivos

Tener un algoritmo entrenado con críticas de usuarios en internet capaz de recomendar libros basandose en la similaridad de mis criticas a las de los demás usuarios

### 1.3 Adquisición de Datos y Preprocesamiento

Los datos vendrán de dos fuentes: - Kaggle - Goodreads

Kaggle nos servirá para conseguir el gran volumen de datos necesario para entrenar el modelo, y viene separado en tres archivos - Books.csv - Users.csv - Ratings.csv

### 1.3.1 Kaggle

El dataset contiene 278,858 users (anonimos pero con informacion demografica) que escribieron 1,149,780 ratings sobre 271,379 librosß. ### Books.csv Cada uno de los libros en Books.csv tiene los siguientes elementos: - ISBN - Book-Title - Book-Author - Year-Of-Publication - Publisher - Image-URL-S - Image-URL-M - Image-URL-L

Solamente usaremos el ISBN del libro para identificar las criticas que le corresponden. El ISBN es el ID del libro, identifica el volumen con un codigo de 10 digitos. El titulo y autor solamente nos servira para identificar el libro ante el usuario, pero por claridad se conservara en este notebook.

Users.csv Lus usuarios tienen tres datos en el .csv: - User-ID - Location - Age

Primariamente nos interesa el ID para asociarlo con las criticas, no tanto la ubicación o la edad

Ratings.csv Este es el archivo que nos interesa mas para el proyecto, contiene criticas de los libros que usaremos para calcular cuales titulos recomendar en funcion de los libros que al usuariomle han gustado: - User-ID - ISBN - Book-Rating

# 1.4 Imports

```
[223]: import numpy as np
   import pandas as pd
   from scipy.sparse import csr_matrix
   from sklearn.neighbors import NearestNeighbors
   import matplotlib.pyplot as plt
   import warnings
   import os, sys
   import re

warnings.filterwarnings('ignore')
   pd.set_option('display.max_colwidth', None)
```

### 1.4.1 Load Books

3

Gina Bari Kolata

```
[224]: df books = pd.read csv('../data/raw/Books.csv')
       df_books.head()
[224]:
                ISBN \
       0 0195153448
       1 0002005018
       2 0060973129
       3 0374157065
       4 0393045218
                  Book-Title \
       0
       Classical Mythology
       Clara Callan
      Decision in Normandy
       3 Flu: The Story of the Great Influenza Pandemic of 1918 and the Search for the
      Virus That Caused It
       The Mummies of Urumchi
                  Book-Author Year-Of-Publication
                                                                     Publisher \
           Mark P. O. Morford
                                                       Oxford University Press
       0
                                              2002
        Richard Bruce Wright
                                              2001
                                                         HarperFlamingo Canada
       1
                  Carlo D'Este
                                                               HarperPerennial
       2
                                              1991
```

1999

Farrar Straus Giroux

```
4
              E. J. W. Barber
                                             1999 W. W. Norton & Damp; Company
                                                           Image-URL-S \
      0 http://images.amazon.com/images/P/0195153448.01.THUMBZZZ.jpg
      1 http://images.amazon.com/images/P/0002005018.01.THUMBZZZ.jpg
      2 http://images.amazon.com/images/P/0060973129.01.THUMBZZZ.jpg
      3 http://images.amazon.com/images/P/0374157065.01.THUMBZZZ.jpg
      4 http://images.amazon.com/images/P/0393045218.01.THUMBZZZ.jpg
                                                           Image-URL-M \
      0 http://images.amazon.com/images/P/0195153448.01.MZZZZZZZ.jpg
      1 http://images.amazon.com/images/P/0002005018.01.MZZZZZZZ.jpg
      2 http://images.amazon.com/images/P/0060973129.01.MZZZZZZZ.jpg
      3 http://images.amazon.com/images/P/0374157065.01.MZZZZZZZ.jpg
      4 http://images.amazon.com/images/P/0393045218.01.MZZZZZZZ.jpg
                                                           Image-URL-L
      0 http://images.amazon.com/images/P/0195153448.01.LZZZZZZZ.jpg
      1 http://images.amazon.com/images/P/0002005018.01.LZZZZZZZZ.jpg
      2 http://images.amazon.com/images/P/0060973129.01.LZZZZZZZZ.jpg
      3 http://images.amazon.com/images/P/0374157065.01.LZZZZZZZZ.jpg
      4 http://images.amazon.com/images/P/0393045218.01.LZZZZZZZ.jpg
      Drop unwanted columns
[225]: df_books = df_books[['ISBN', 'Book-Title', 'Book-Author']]
      df_books.head()
[225]:
               ISBN \
      0 0195153448
      1 0002005018
      2 0060973129
      3 0374157065
      4 0393045218
                 Book-Title \
      Classical Mythology
      Clara Callan
      Decision in Normandy
      3 Flu: The Story of the Great Influenza Pandemic of 1918 and the Search for the
      Virus That Caused It
      The Mummies of Urumchi
                  Book-Author
```

```
Richard Bruce Wright
       1
       2
                  Carlo D'Este
       3
              Gina Bari Kolata
               E. J. W. Barber
      1.4.2 Load ratings
[226]: df_ratings = pd.read_csv('../data/raw/Ratings.csv')
       df_ratings.head()
[226]:
          User-ID
                         ISBN
                               Book-Rating
           276725
                   034545104X
           276726
                   0155061224
                                          5
       1
       2
           276727
                   0446520802
                                          0
       3
           276729 052165615X
                                          3
           276729 0521795028
                                          6
      1.5 Clean Nulls
[227]: df_books.isnull().sum()
[227]: ISBN
                      0
       Book-Title
                      0
       Book-Author
                      2
       dtype: int64
[228]: df_ratings.isnull().sum()
[228]: User-ID
                      0
       ISBN
                      0
       Book-Rating
                      0
       dtype: int64
[229]: df_books.dropna(inplace=True)
       df_books.isnull().sum()
[229]: ISBN
                      0
                      0
       Book-Title
       Book-Author
       dtype: int64
[230]: df_books.shape
[230]: (271358, 3)
[231]: df_ratings.shape
```

0

Mark P. O. Morford

```
[231]: (1149780, 3)
```

# 1.6 Procesar ratings

Analizamos cuantos ratings han escrito los usuarios con el mayor numero de entradas. Podemos ver que los usuarios mas prolificos tienen miles de ratings a su nombre

```
[232]: ratings = df_ratings['User-ID'].value_counts()
ratings.sort_values(ascending=False).head()
```

```
[232]: User-ID

11676 13602

198711 7550

153662 6109

98391 5891

35859 5850

Name: count, dtype: int64
```

Hacemos la operacion inversa y vemos que hay usuarios con tan solo un rating. Vamos a desechar a los usuarios con menos de un numero criticas para asegurarnos que solo la gente con cierto nivel de experiencia pueda contribuir al entrenamiento de nuestro recomendador

Veremos cuantos usuarios hay con menos de x ratings para ver cual es nuestro numero minimo de criticas

```
[234]: print("Total de usuarios: ",df_ratings.shape[0])

print("Usuarios con menos de 5 ratings: ", len(ratings[ratings < 5]))
print("Usuarios con menos de 10 ratings: ", len(ratings[ratings < 10]))
print("Usuarios con menos de 50 ratings: ", len(ratings[ratings < 50]))
print("Usuarios con menos de 100 ratings:", len(ratings[ratings < 100]))
print("Usuarios con menos de 150 ratings:", len(ratings[ratings < 150]))
print("Usuarios con menos de 200 ratings:", len(ratings[ratings < 200]))
```

```
Total de usuarios: 1149780
Usuarios con menos de 5 ratings: 82467
Usuarios con menos de 10 ratings: 92186
Usuarios con menos de 50 ratings: 101856
Usuarios con menos de 100 ratings: 103436
```

```
Usuarios con menos de 150 ratings: 104049
Usuarios con menos de 200 ratings: 104378
```

Vemos que no hay tanta diferencia despues de quitar a los usuarios con menos de 5 ratings en el volumen total de datos. En el resto del proyecto quitaremos los usuarios con menos de 10 ratings

```
[235]: df_ratings['User-ID'].isin(ratings[ratings < 10].index).sum()
[235]: np.int64(184067)
[236]: df_ratings_rm = df_ratings[
         ~df_ratings['User-ID'].isin(ratings[ratings < 10].index)</pre>
       df_ratings_rm.shape
[236]: (965713, 3)
      Hacer lo mismo para libros con menos de 100 ratings
[237]: ratings = df_ratings['ISBN'].value_counts()
       ratings.sort_values(ascending=False).head()
[237]: ISBN
       0971880107
                      2502
       0316666343
                      1295
       0385504209
                       883
       0060928336
                       732
                       723
       0312195516
       Name: count, dtype: int64
[238]: ratings.sort_values(ascending=True).head()
[238]: ISBN
       0671883917
                      1
       0060164220
                      1
       0316185922
                      1
       1931333246
                      1
       0140260676
       Name: count, dtype: int64
[239]: print("Libros de usuarios:
                                                ",ratings.shape[0])
       print("Libros con menos de 20 ratings: ", len(ratings[ratings < 20]))</pre>
       print("Libros con menos de 50 ratings: ", len(ratings[ratings < 50]))</pre>
       print("Libros con menos de 100 ratings:", len(ratings[ratings < 100]))</pre>
                                         340556
      Libros de usuarios:
      Libros con menos de 20 ratings:
                                         333066
      Libros con menos de 50 ratings:
                                         338371
      Libros con menos de 100 ratings: 339825
```

```
[240]: df_ratings_rm = df_ratings_rm[
    ~df_ratings_rm['ISBN'].isin(ratings[ratings < 100].index)
]
df_ratings_rm.shape</pre>
```

[240]: (108113, 3)

Tenemos nuestro dataset de ratings con user, ISBN y calificacion

```
[241]: df_ratings_rm.head()
```

[241]:		User-ID	ISBN	Book-Rating
	34	276762	0451167317	0
	133	276822	0060096195	10
	145	276822	0786817070	10
	173	276847	0446364193	0
	413	276925	002542730X	10

Generamos la matriz de usuario-libro con el valor de la cel<br/>da siendo la calificacion. Si no ha dado un rating para ese libro lle<br/>namos con 0

	di.Head()											
[242]:	User-ID ISBN	99	242	24	3	254	383	38	34	388	408	\
	002542730X	0.0	0.0		0.0	0.0	0	.0	0.0	0.0	0.0	
	0060008032	0.0	0.0		0.0	0.0	0	.0	0.0	0.0	0.0	
	0060096195	0.0	0.0		0.0	0.0	0	.0	0.0	0.0	0.0	
	006016848X	0.0	0.0		0.0	0.0	0	.0	0.0	0.0	0.0	
	0060173289	0.0	0.0		0.0	0.0	0	.0	0.0	0.0	0.0	
	User-ID ISBN	424	446	•••	27841	8 2785	06 2	78522	27853	5 27853	6 \	
	002542730X	0.0	0.0		0.	0 0	.0	0.0	0.	0 0.	0	
	0060008032	0.0	0.0		0.		.0	0.0	0.			
	0060096195	0.0	0.0	•••	0.		.0	0.0	0.			
	006016848X	0.0	0.0		0.		.0	0.0	0.			
	0060173289	0.0	0.0		0.	0 0	.0	0.0	0.	0 0.	0	
	User-ID ISBN	278554	278582	27	8633	278771	2788	43				
	002542730X	0.0	0.0		0.0	0.0	0	.0				
	0060008032	0.0	0.0		0.0	0.0	0	.0				
	0060096195	9.0	0.0		0.0	0.0	0	.0				

006016848X	0.0	0.0	0.0	0.0	0.0
0060173289	0.0	0.0	0.0	0.0	9.0

[5 rows x 10164 columns]

Indexamos la matriz con el titulo del libro para buscar el libro por titulo en vez del ISBN

```
[243]: df.index = df.join(df_books.set_index('ISBN'))['Book-Title']
df = df.sort_index()
df.head()
```

[243]:	User-ID Book-Title	99	242	243	254	383	384 ;	388 \
	1984	0.0	0.0	0.0	9.0	0.0	0.0	0.0
	1st to Die: A Novel	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	1st to Die: A Novel	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	2nd Chance	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	2nd Chance	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	User-ID	408	424	446	2784	18 278506	6 27852:	2 \
	Book-Title				•••			
	1984	0.0	0.0	0.0	0	0.0	0.0	0
	1st to Die: A Novel	0.0	0.0	0.0	0	0.0	0.0	0
	1st to Die: A Novel	0.0	0.0	0.0	0	0.0	0.0	0
	2nd Chance	0.0	0.0	0.0	0	0.0	0.0	0
	2nd Chance	0.0	0.0	0.0	0	0.0	0.0	0
	User-ID	278535	278536	278554	278582	278633	278771	278843
	Book-Title	0 0	0 0	0 0	0 0	0 0	0 0	0 0
	1984	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	1st to Die: A Novel	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	1st to Die: A Novel	10.0	0.0	0.0	0.0	0.0	0.0	0.0
	2nd Chance	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	2nd Chance	0.0	0.0	0.0	0.0	0.0	0.0	0.0

[5 rows x 10164 columns]

Probamos que exista un libro, en este caso Lord of the Rings. Usaremos el titulo que usa el dataset para el libro 16 Lighthouse Road para probar el modelo ya que lo tengamos entrenado

```
[244]: df.loc["The Fellowship of the Ring (The Lord of the Rings, Part 1)"][:5]
```

```
[244]: User-ID

99 0.0

242 0.0

243 0.0

254 0.0

383 0.0
```

Name: The Fellowship of the Ring (The Lord of the Rings, Part 1), dtype: float64

### 1.7 Modelo

#### 1.7.1 Creacion del modelo

Usaremos un modelo de KNN para hacer las recomendaciones. La distancia sera conseguida en base la similaridad de las criticas de ese libro con las criticas de otros libros. Si los mismos usuarios le dieron calificaciones similares a dos libros diremos que ese segundo libro deberia ser recomendado a los usuarios que les gusto el primero

## 1.8 Conseguir recomendaciones

Usaremos un K de 6 para esta prueba

Metemos las recomendaciones a un DataFrame de pandas con el titulo recomendado y la distancia del libro original

```
[249]: pd.DataFrame({
    'title' : df.iloc[indice[0]].index.values,
    'distance': distance[0]
}) \
    .sort_values(by='distance', ascending=False)
```

```
[249]:
                                                                        title \
      5
                               Ender's Game (Ender Wiggins Saga (Paperback))
      4 Lasher: Lives of the Mayfair Witches (Lives of the Mayfair Witches)
                The Hobbit: The Enchanting Prelude to The Lord of the Rings
      3
      2
                               The Two Towers (The Lord of the Rings, Part 2)
                       The Return of the King (The Lord of the Rings, Part 3)
      0
                  The Fellowship of the Ring (The Lord of the Rings, Part 1)
         distance
      5 0.907733
      4 0.902908
      3 0.737266
      2 0.589064
      1 0.555667
      0.000000
```

Creamos una funcion para simplificar el proceso de conseguir k recomendaciones para un titulo

```
[250]: def get_recommends(title = "", k = 10):
    try:
        book = df.loc[title]
    except KeyError as e:
        return None

    distance, indice = model.kneighbors([book.values], n_neighbors=k)

    recommended_books = pd.DataFrame({
        'title' : df.iloc[indice[0]].index.values,
        'distance': distance[0]
        }) \
        .sort_values(by='distance', ascending=False) \
        .head(5).values

    return [title, recommended_books]
```

### 1.9 Revisar predicciones

```
[252]: books = get_recommends("Dune (Remembering Tomorrow)")
      print(books)
      ['Dune (Remembering Tomorrow)', array([['Siddhartha', 0.9222937976819585],
             ['The Hobbit : The Enchanting Prelude to The Lord of the Rings',
              0.9206880350806068],
             ["The Handmaid's Tale", 0.9204704161591308],
             ['Dreamcatcher', 0.9198527770815851],
             ['A Confederacy of Dunces (Evergreen Book)', 0.9194667585125214]],
            dtype=object)]
[253]: books = get_recommends("American Gods")
      print(books)
      ['American Gods', array([["The Bonesetter's Daughter", 0.9317207157574144],
             ['A Prayer for Owen Meany', 0.9296579620815202],
             ["Lamb : The Gospel According to Biff, Christ's Childhood Pal",
              0.9238304529803233],
             ['Love in the Time of Cholera (Penguin Great Books of the 20th Century)',
              0.9222952032805442],
             ["Slaughterhouse Five or the Children's Crusade: A Duty Dance With
      Death",
              0.9215509071275683]], dtype=object)]
[254]: books = get recommends("The Fellowship of the Ring (The Lord of the Rings, Part,
       print(books)
      ['The Fellowship of the Ring (The Lord of the Rings, Part 1)', array([['Harry
      Potter and the Chamber of Secrets (Book 2)',
              0.9193624743457263],
             ['Harry Potter and the Goblet of Fire (Book 4)',
              0.9179158381435988],
             ["Harry Potter and the Sorcerer's Stone (Harry Potter (Paperback))",
              0.913950465507235],
             ['The Tale of the Body Thief (Vampire Chronicles (Paperback))',
              0.9108658383837844],
             ["Ender's Game (Ender Wiggins Saga (Paperback))",
              0.9077326601838696]], dtype=object)]
```

### 1.10 Evaluaciones

La manera de evaluar este proyecto será de acuerdo a dos criterios: - Existen recomendaciones para mis libros favoritos - Me son útiles las recomendaciones Usamos estos dos criterios porque la meta de este proyecto es darme recomendaciones basadas en mis libros favoritos.

#### 1.10.1 Métricas

Usaremos un export de mi librería de Goodreads que entre otras columnas tiene las siguientes: - ISBN - Título - Bookshelves Las primeras dos columnas se usarán para buscar libros con el modelo KNN, la tercer columna de Bookshelves tiene las categorías que yo les he dado. Una de estas categorías es la de "favorites", la cual indica que yo personalmente marqué este libro como uno de mis favoritos. Usaremos estos libros para ver cuantos de ellos tienen recomendaciones.

```
[255]: df books = pd.read csv('../data/raw/goodreads library export.csv')
       df_books.head()
[255]:
            Book Id
                                                              Title
                                                                                 Author
           62015945
                            Yours Truly (Part of Your World, #2)
                                                                           Abby Jimenez
       0
       1
          195834342
                                               Just for the Summer
                                                                           Abby Jimenez
       2
          220422953
                      Fighting Past Pain (Heavenly Chaos Book 2)
                                                                     Daniel Schinhofen
          216035586
                                       Saviors (Quest Academy #3)
                                                                       Brian J. Nordon
       3
          203274611
                                    Scavengers (Quest Academy #2)
                                                                       Brian J. Nordon
                   Author 1-f Additional Authors
                                                              ISBN
                                                                               ISBN13
       0
                Jimenez, Abby
                                               NaN
                                                    ="1538704412"
                                                                    ="9781538704417"
                Jimenez, Abby
                                               NaN
                                                               =""
       1
       2
                                                               =""
                                                                                  _" "
          Schinhofen, Daniel
                                               NaN
                                                               =""
                                                                                  =""
       3
            Nordon, Brian J.
                                               NaN
       4
            Nordon, Brian J.
                                               NaN
                                                               =""
                                                                                  =""
                      Average Rating
                                                        Publisher
                                                                         Date Read
          My Rating
       0
                   0
                                 4.32
                                                         Forever
                                                                       2024/11/03
       1
                   0
                                 4.39
                                                          Forever
                                                                               NaN
       2
                   0
                                 4.73
                                                               NaN
                                                                               NaN
       3
                   5
                                 4.72
                                       The Legion Publishers 1td
                                                                       2024/11/02
       4
                   5
                                 4.53
                                       The Legion Publishers Ltd
                                                                       2024/11/01
          Date Added
                             Bookshelves
                                           Bookshelves with positions
          2024/10/04
                                      NaN
                                                                    NaN
       1
          2024/11/03
                       currently-reading
                                               currently-reading (#22)
          2024/11/02
                       currently-reading
                                               currently-reading (#21)
       2
       3
          2024/11/01
                                      NaN
                                                                    NaN
          2024/10/31
                                      NaN
                                                                    NaN
            Exclusive Shelf My Review Spoiler Private Notes Read Count
                                                                             Owned Copies
       0
                        read
                                    NaN
                                             NaN
                                                           NaN
                                                                                         0
                                                                          1
          currently-reading
                                                                          1
                                                                                         0
       1
                                    NaN
                                             NaN
                                                           NaN
       2
          currently-reading
                                    NaN
                                             NaN
                                                           NaN
                                                                          1
                                                                                         0
       3
                        read
                                    NaN
                                             NaN
                                                           NaN
                                                                          1
                                                                                         0
```

[5 rows x 24 columns]

read

4

NaN

1

0

NaN

NaN

```
[256]: df_books = df_books[['ISBN', 'Title', 'Bookshelves']]
       df_books.head()
[256]:
                   ISBN
                                                                Title \
          ="1538704412"
                                Yours Truly (Part of Your World, #2)
       0
                                                 Just for the Summer
       1
                    =""
       2
                         Fighting Past Pain (Heavenly Chaos Book 2)
                    =""
                                          Saviors (Quest Academy #3)
       3
                    =""
       4
                                       Scavengers (Quest Academy #2)
                Bookshelves
       0
                        NaN
       1
          currently-reading
       2
          currently-reading
       3
                        NaN
       4
                        NaN
[257]: df_books.dropna(inplace=True)
       df_books = df_books[df_books['Bookshelves'].str.contains('favorites')]
       df_books['ISBN'] = df_books['ISBN'].str.replace('="', '').str.replace('"', '')
       df_books.head()
[257]:
                  ISBN
       30
            0451465105
       63
       210
       215
       222
                                                                      Title \
                            The Thousand Names (The Shadow Campaigns, #1)
       30
       63
                                                        Dreamer's Throne 2
       210
                                           Sex, Death, and Money: Season 1
                       The Path of Ascension 3 (The Path of Ascension #3)
       215
            Homicidal Aliens are Invading and All I Got is This Stat Menu
       222
                          Bookshelves
       30
                            favorites
       63
                            favorites
       210
                            favorites
       215
                    litrpg, favorites
       222
            favorites, supers, litrpg
[258]: df_books['Recommendations'] = df_books['Title'].apply(lambda x:__
       ⇒get_recommends(x, k=10))
       df_books.groupby('Recommendations').count()
```

[258]: Empty DataFrame

Columns: [ISBN, Title, Bookshelves]

Index: []

# 1.11 Resultados

No conseguimos ninguna recomendación para los libros que tengo marcados como mis favoritos. Esto nos deja con dos conclusiones: 1. El dataset no tiene suficiente variedad de libros 2. Mis gustos lectores son demasiado de nicho como para usar este modelo 3. Debemos de consolidar los títulos de las diferentes ediciones en un sólo índice para tener más críticas por libro